

Integração de Dados

Licenciatura em Engenharia Informática: 2º ano - 2º semestre

2025/2026

Trabalho Prático *Integração de Dados com XML*

Nota prévia: O enunciado é propositadamente vago, genérico e incompleto em alguns pontos. O que se pretende é que os alunos avaliem as várias opções existentes e escolham a que considerarem mais apropriada para cada uma das situações com que se depararem. Todas as escolhas devem ser referidas e devidamente justificadas no relatório a entregar.

1. OBJETIVOS

Com este trabalho pretende-se criar uma aplicação em Java composto por vários Wrappers que obtenham dados de duas fontes heterogéneas, distribuídas e autónomas e possibilitem ao utilizador a visualização dos dados de forma integrada.

O utilizador terá ainda a possibilidade de fazer pesquisas, acrescentar dados que respeitem os esquemas adotados e gerar ficheiros com informação selecionada.

Para a realização deste trabalho deve usar a Linguagem Java, Expressões regulares, JSoup e os APIs JDOM e SAXON estudados nas aulas práticas.

2. RESULTADOS DA APRENDIZAGEM

Com este trabalho prático pretende-se que se adquiram as seguintes competências:

- Saber analisar uma situação típica de Integração de Dados e apresentar propostas válidas para um modelo de integração funcional, robusto, eficaz e correto;
- Capacidade de criação e manipulação de XML
- Utilização de expressões regulares
- Utilização da biblioteca JSoup
- Capacidade de realização de pesquisa de informação em ficheiros XML usando XPath e/ou XQuery
- Capacidade de efetuar transformações de ficheiros XML usando XSLT e/ou XQuery
- Capacidade de efetuar validação de ficheiros XML usando DTD e/ou XSD

3. DESCRIÇÃO DO TRABALHO

O objetivo do trabalho consiste na criação de uma aplicação integradora que apresente uma vista unificada de informação relativa a **raças de cães**, proveniente de duas páginas da Internet:

- <https://www.royalkennelclub.com/search/breeds-a-to-z/>
 - Deste site, obter link de cada raça usando jsoup.
 - Da página individual de cada raça, implementar os wrappers para extrair os detalhes usando jsoup
- https://en.wikipedia.org/wiki/breed_name
 - EXEMPLO: <https://en.wikipedia.org/wiki/beagle>

As duas fontes de dados são heterogêneas, autônomas e distribuídas e contêm informação relevante sobre diversas raças de cães. Deve usar a página da Wikipédia em inglês para facilitar a integração com a segunda fonte de dados que é uma página americana.

O objetivo do trabalho prático consiste em efetuar **integração de dados** provenientes destas fontes de dados. A extração de dados deve usar as tecnologias abordadas nas aulas:

- Wikipedia – usar Expressões regulares
- Royal Kennel Club – usar Jsoup

Dados a extrair para cada raça:

Foto representativa da raça, grupo (toy, working, hound, ...), detalhes do tamanho (small, medium, large, altura, peso para fêmeas e machos), cuidados com o pelo, nível de exercício, cores, país de origem, esperança de vida, tamanho do pelo.

NOTA: Os valores numéricos devem ser tratados para poderem ser corretamente manipulados por pesquisas XPATH/XQUERY. Este tratamento pode passar por eliminar o separador dos milhares, eliminar espaços em branco, colocar o separador decimal como . (ponto) em vez de , (virgula), etc.

O esquema a adotar na vista unificada deve ser decidido pelos alunos e validado usando o XSD e o DTD apropriado.

Depois de realizado o processo de integração dos dados, o utilizador poderá fazer pesquisas sobre a vista unificada.

4. TAREFAS A REALIZAR

Encontram-se em seguida as tarefas principais a desenvolver neste trabalho prático. As descrições são genéricas e os exemplos apresentados servem apenas para uma melhor compreensão do que é pretendido. Os alunos devem ser criativos e apresentar uma solução integradora completa e funcional que permita efetuar uma grande diversidade de pesquisas.

4.1. ANALISAR AS FONTES DE DADOS (S)

A primeira parte do trabalho consiste em procurar todos os atributos acima descritos para uma raça introduzida pelo utilizador. Tem algumas raças para teste no ficheiro **racas.txt**. A informação recolhida deve ser organizada **em dois ficheiros XML**. O primeiro ficheiro (raças.xml) deve ter apenas a listagem das raças pesquisadas com o nome da raça e um identificador único gerado pela implementação. No segundo ficheiro (detalhes.xml) devem estar os detalhes de cada raça pesquisada.

4.2. DEFINIR O ESQUEMA GLOBAL (G)

Defina um modelo global para a recolha dos dados. Este modelo deve ser baseado num modelo de dois ficheiros XML com a estrutura hierárquica adequada ao problema proposto. Isto é, o aluno deve analisar qual a estrutura dos ficheiros que considera mais adequada no que se refere ao nível de ramificação e à escolha de elementos ou atributos para guardar os dados. O esquema a adotar na vista unificada decidido pelos alunos deve ser sempre validado usando o XSD e o DTD apropriado.

4.3. IMPLEMENTAR WRAPPERS (MAPEAMENTOS M)

Implementar os *Wrappers* que permitam obter a informação relevante de cada fonte de dados. Estes *Wrappers* devem ser implementados usando expressões regulares (wikipedia) e Jsoup (Royal Kennel Club). No relatório deve ser descrito detalhadamente cada um dos wrappers, indicando que informação é retirada por cada um deles da fonte de dados em que cada um opera.

Para cada atributo a encontrar, deve(m) ser selecionada(s) a(s) fonte(s) de dado(s) relevante(s). No caso de encontrar inconsistências ou conflitos os alunos terão de propor uma solução.

4.4. GERAR / MANIPULAR FICHEIRO XML: ACRESCENTAR, EDITAR E ELIMINAR DADOS

Depois de implementados os wrappers, os dados devem ser guardados em ficheiro(s) XML usando o modelo escolhido. Deverá ser possível:

- Adicionar uma nova raça, desde que este não exista no ficheiro **raças.xml** e respetivos detalhes (em **detalhes.xml**)
- Se os ficheiros não existirem ainda, devem ser criados com a inserção da primeira raça e respetivos detalhes em ambos os ficheiros.
- Eliminar uma raça (usar nome da raça como palavra de pesquisa). Deve ser eliminada a informação de ambos os ficheiros.
- Editar/alterar alguns atributos do ficheiro **detalhes.xml**

4.5. VALIDAR O MODELO G

Os ficheiros do modelo G devem ser validados usando os XSD/DTD escolhidos.

Esta tarefa deve ser feita usando o API JDOM2 dado nas aulas práticas.

4.6. FAZER PESQUISAS XPATH

Permitir ao utilizador efetuar diferentes pesquisas sobre o modelo XML:

- Pesquisar pelo nome da raça e mostrar a informação sobre os detalhes
- Procurar raças de um determinado porte (small, medium, large, ...)
- Procurar raças com peso entre dois valores definidos pelo utilizador;
- Solicitar ao utilizador que tipo de cão pretende (por exemplo com elevado nível de exercício, de pelo curto, etc) e mostrar as raças.
- Combinar dois ou mais atributos em diferentes pesquisas. Por exemplo, animais pequenos com origem em Inglaterra
- Todas as raças que existam com uma cor definida pelo utilizador
-

4.7 GERAR FICHEIROS DE OUTPUT (XSLT/XQUERY)

O programa deve possibilitar ao utilizador gerar ficheiros de resultados. Estes ficheiros devem ser transformações do modelo XML da vista global.

Pretendem-se quatro transformações obrigatórias:

- Gerar ficheiro HTML com o nome da raça e a fotografia de todos as raças inseridas no ficheiro (sem repetições)
- Gerar um novo ficheiro XML que organize os cães do ficheiro **raças.xml** por **tamanho**
- Gerar um ficheiro XML com os detalhes dos cães de uma raça introduzida pelo utilizador
- Pedir ao utilizador o nome de uma raça e gerar um ficheiro HTML que mostre uma lista dos detalhes dessa raça

Os alunos devem propor no mínimo **mais três** transformações adicionais. Devem implementar as transformações usando as duas tecnologias dadas nas aulas - XSLT e XQuery – optando pela que for mais adequada em cada situação.

4.8. INTERFACE GRÁFICO

A aplicação deve ter uma interface amigável e intuitiva, disponibilizando ao utilizador um conjunto de opções. Por exemplo, sugere-se a seguinte estrutura:

- Opções gerais
 - Ver conteúdo dos ficheiros XML
 - Validar modelo de dados (DTD e XSD)
 - Sair da aplicação
- Alterar dados do modelo XML (efetue sempre a validação do modelo em cada uma das opções)
 - Eliminar uma raça dos ficheiros (usar nome como palavra de pesquisa)
 - Acrescentar uma raça e respetivos detalhes que não existam nos ficheiros
 - Alterar alguns atributos dos detalhes de uma raça introduzida pelo utilizador
- Efetuar Pesquisas XPATH
- Gerar Outputs XSLT / XQUERY

5. NORMAS PARA REALIZAÇÃO DO TRABALHO

O trabalho deverá ser **em grupos de dois alunos**.

O trabalho vale 6 valores e é necessário um mínimo de 35% para aprovação na Unidade Curricular.

O trabalho final deve ser entregue até **17 de Maio de 2026** às 23h59 GMT.

>>>>>> DATA ÚNICA DE ENTREGA PARA TODAS AS ÉPOCAS DE EXAME <<<<<<<

A entrega dos trabalhos deverá ser feita usando a plataforma Moodle. Deve ser submetido um ficheiro compactado cujo nome deve conter a identificação dos elementos do grupo de trabalho:

Por exemplo: **a22222_AnaMatos_a33333_RuiMelo_P1.zip**

O ficheiro deve conter o projeto Java com a implementação da aplicação e todos os ficheiros XML, DTD, XSD, XSLT, XQuery, etc que foram implementados.

Os trabalhos serão sujeitos a **defesa obrigatória** na semana 18 a 22 de Maio. As inscrições para as defesas serão disponibilizadas no Moodle.

6. CRITÉRIOS DE AVALIAÇÃO

O trabalho vale **6 valores** na nota final da Unidade Curricular.

Será avaliado segundo os seguintes critérios:

- Qualidade e correção na implementação das tarefas solicitadas
- Funcionalidade e robustez do programa
- Originalidade e diversificação dos conteúdos abordados, nomeadamente as funcionalidades extras
- Justificação das opções tomadas
- Qualidade do relatório entregue
- Funcionalidade do interface
- Relatório
- Qualidade da defesa

7. UTILIZAÇÃO DE FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

Os estudantes podem usar ferramentas de IA de forma responsável e crítica.

Não serão aceites trabalhos com código gerado por IA.

Não serão aceites trabalhos com relatórios gerados por IA.

Durante a defesa os alunos terão de ser capazes de:

- Explicar detalhadamente o código implementado

- Alterar o código implementado de acordo com o que lhes for solicitado

- Implementar novas funções semelhantes às realizadas neste trabalho

No caso de uma defesa em que estas tarefas não sejam minimamente cumpridas **o trabalho será anulado**.